CourseLoop 数据说明与数据卡

盘点日期：2026-10-09 UTC。数据规模引用 测试环境盘点，采用只读计数和字段结构。2026-10-10 完成处理后内容导出；交付范围见 处理后数据交付范围。本次导出为 4810 题、220 知识点与 2646 检索块，详情见交付数据清单。历史测试环境盘点 4808 题对应当时容量实验，分别保留口径。

部分数据来源于南京理工大学计算机科学与工程学院本科生自建数据库。数据经课程归类、题目与答案规范化、知识点关联、资料分块及索引处理后用于比赛原型与评审，并保留来源与引用定位。

一、数据资产与用途

数据层	规模与用途	是否随仓库分发
处理后交付题库	4 课程、4810 题，6086 判题样例、383 规则项、4980 题目知识点关联	下载运行包内容表与数据清单
交付资料索引	FTS5 共 2646 块；ds-algo1767、co361、os104、net414	下载运行包提供 2646 处理后检索块与定位字段
课程大纲与知识点	考纲条目与入库知识点为不同口径；本次导出 knowledge_points220 行	交付内容表与默认课程配置源码
原创交付演示	原项目 16 种子题 + 本次 20 原创单选，4 原创短讲义及少量合成画像	生成脚本在 Git；实际库在下载运行包
个人学习行为	用户、作答、错题、掌握度、会话、复习、作业与人工复核	只保留表结构与规模，真实记录不复制
历史 SFT/GRPO	历史报告记载 8899 训练、467 验证、2800 GRPO 样本；为历史口径	源码、方法与聚合报告；不分发原始训练集或权重

生成题 1530 道带非空资料引用，可按来源标签追溯数据进入系统的途径。第三方材料及其派生内容遵循相应授权范围；仓库保持私有，用于本次比赛评审。v1.0 采用上述处理后内容范围；原创演示与 GPU 实验按各自实际数据规模说明。

4090D 独立部署同样从零生成 36 题 / 4 讲义及虚构账号，不复制在线演示环境个人记录。GPU 计时提示使用原创课程概念材料，完整提示、实际 token 用量、生成输出和采样在 gpu-4090d/benchmark.json 中提供；模型文件摘要见 inventory.json，授权权重不随仓库分发。

二、主要字段字典

完整表列、类型、默认值和主键见 字段字典。SQLite 使用幂等建表及 ALTER 迁移，业务关联通过代码维护，并结合事务和对账验证一致性；外键强约束覆盖作为后续工程增强项。

表	关键字段	语义与限制
courses	id、display、score、knowledge_taxonomy、enabled	课程身份、分值、大纲 JSON 与启用状态
knowledge_points	id、course_id、chapter、name、difficulty	课程下知识点；difficulty 为 1—5 工程基线，非 IRT 标定
problems	id、course_id、source、type、stem、answer、verification_type、func_name、ref_code、citations	题干、参考答案或 canonical JSON、判分类型、代码入口和出处
problem_knowledge	problem_id、knowledge_id、weight	题目与知识点多对多，weight 默认 1
test_cases	problem_id、input、expected_output、hidden	JSON 参数与期望结果；hidden 样例不直接公开细节
rubric_items	description、score、expected_evidence	可解释的规则得分点及分值；复杂语义结合模型说明与人工复核
chunks	text、course、doc_type、source、title_path、page_start、page_end、chunk_index	FTS 正文及引用定位；0 页表示材料无真实页码
chunk_hashes	hash、course、source、chunk_index	课程 + 归一化正文哈希，支持内容去重
users	username、role、pw_hash、salt、status、资料字段	账户权限、盐化散列及个人资料；生产行和原密码不交付
learning_sessions / dialog_turns	username、intent、state；session_id、role、content、structured_data	学习会话、轮次、引用与生成结构；按用户归属访问
tutor_snapshots	db_session_id、session_id、username、snapshot	TutorGraph 状态恢复，snapshot 含 JSON
practice_attempts	username、problem_id、knowledge_id、session_id、answer、score、hints_used、duration	用户作答、判分、提示及耗时秒；自由题可 problem_id=0
error_records	error_type、diagnosis、problem_stem、student_answer、resolved、review_reason、ta_*	错因、上下文、复核和销账；tech_detail 仅教学侧需审查
mastery_records / snapshots	mastery、confidence、state、review_stage、next_due_at	当前工程估计与追加历史；0—1 值用于学习调度，统计概率标定另行研究

表	关键字段	语义与限制
review_plans / tasks	start_date、exam_date、budget_snapshot；stage、minutes、due_from/to、tier	复习计划、预算快照、间隔、到期窗与必做选做
study_budgets / exceptions	weekly_minutes、intensity、buffer_weekday；date、minutes	用户级周预算和例外日期，各课程共享
assignments	ta_username、knowledge_ids、class_name、target_count、due_date	教学作业；完成度依据实际作答记录聚合
review_requests	question、ai_answer、no_evidence、ta_reply、status	对非错题问答的人工复核，避免污染错题统计
ingest_jobs	filename、stored_path、status、parsed/indexed/duplicate_chunks、uploaded_by	资料解析与生命周期；路径和上传身份按管理员权限保护

三、预处理流程

资料：按课程 / 资料类型发现文件，解析 PDF、PPTX、DOCX、TXT，扫描件需视觉 OCR；保留页码或标题。按章节 / 页 / 标题分块，长文兜底切分；按课程与规范化文本 SHA-256 去重，写入 FTS。撤下资料移到 withdrawn，不再被 raw 重扫；恢复重新解析。

题库：抽取 / 生成题统一课程与知识点，规范选项和 canonical 答案；代码参考解经样例检查，概念题保存得分点，生成题保存引用。题目入库与验证状态分开管理，按实际状态组织自动验证、模型辅助和人工复核；下一阶段通过答案规范化与 kind 扩展提升验证覆盖。训练样本通过格式、结构与验证筛选，按课程 / 任务组织；复训时依据实际资产重新审计 held-out 与训练去重。

学习记录：统一 judge_answer 判分后保存作答、更新掌握度、存错题 / 销错题，复习与班级统计读相同关联。教师复核保留 AI 原错因，向学生提供结论和备注；合成示例明确标注来源，不作为真人实验样本。

四、脱敏与交付策略

下载包从内容表白名单导出处理后数据，从零创建虚构身份；初始作答、会话、学习记录、复核及通知等个人表为空，签名密钥按实例独立生成。ACCESS.md 仅管理本地演示账号，其密码与线上凭据分离；线上评审账号通过比赛指定渠道单独交付。真实姓名、学号、手机号、邮箱及头像不进入演示库，合成班级显式命名比赛演示班。

独立测试只从白名单 courses/app_settings/knowledge_points/problems/test_cases/rubric_items/problem_knowledge 读取内容表，复制 FTS 供实际规模测试；身份与行为全新。最终数据包从内容表白名单独立导出，app_settings 与 FTS 构建环境元信息保持为空；评审账号重新创建。发布前扫描提交文件、ZIP/DOCX 结构、已知线上密钥字节和运行库，核对导出清单及脱敏结果。

实验数据 JSON 采用内容表白名单聚合、schema 与源码摘要，省略实际部署位置、用户统计和个人行为信息。ACCESS.md 提供本地虚构演示凭据；公开数据授权与来源署名按 PUBLICATION.md 及第三方说明分别核对。

五、适用范围与合规要求

处理后内容包提供四课程完整内容部署与比赛评审；源码 bootstrap 另提供原创轻量复现样例。来源署名与脱敏分别管理：署名用于追溯，脱敏用于保护个人信息。第三方教材、课件、真题、OCR 及派生样本遵循权利人授权，公开、训练及商业再分发按对应许可执行。

合成学习轨迹用于业务流程验证，历史 teacher-gold 用于蒸馏一致性评价；真实学生分布、长期教育效果和掌握度参数标定需另设真人样本与独立评价设计。个人信息遵循最小化处理原则，禁止重识别、关联学校名单或对外传播。模型 API 开启时，按供应商数据政策和学校规定审查输入，身份或受限版权材料须完成合规审查后方可发送。