CourseLoop 正式提交版本测试报告

正式交付版本：v1.0。本报告组织已完成的业务容量、GPU 实测与完整处理后内容验收，统一证据目录为 artifacts/evidence/v1.0/，完整内容验收见 processed-data。各实验保留实际源码快照、时间、输入规模与设备条件；交付编号统一不表示重新测量。提交版并发优化通过独立测试验证，视觉链路按专项 API 实验评价；在线演示与本地运行包分别提供功能体验和可复现部署。

一、环境与实验设计

公开交付整理验证：本轮源码回归 628 项通过；处理后运行副本 86 项功能检查通过，100 次同账号并发记录完整、掌握度一致，四课程检索通过。本地演示密码已与线上凭据分离，22 张非身份表逐行保持一致。部署信息与凭据扫描覆盖源码、正式报告、图像及发布附件；冻结版本的核验摘要见 Release 中的 RELEASE-VALIDATION.json。历史容量与 GPU 指标继续按原实验条件呈现。

测试环境容量实验使用 4808 题、2646 检索块，只使用虚构账号、独立数据库和签名密钥。并发阶段的业务代码保持不变；功能、同账号、10/25/50 用户测试串行运行。视觉路由及转写另行进行真实 API 验收，不影响混合业务压测模块。v1.0 下载包提供 4810 题 / 2646 块；原创轻量部署与 GPU 实验使用 36 题 / 4 讲义演示数据。

新增 GPU 交付工具的源码回归在独立云服务器应用环境执行：Python3.10.15，604 项通过，见 JUnit 及完整日志。GPU 性能与该服务器功能、浏览器、真实问答链路按 08 专项报告列示；业务并发模块与测试环境最终压测源码一致。

单 Uvicorn worker；20%确定性单选判题写入、80%业务读取；每用户思考 0.1 秒。10 人 60 秒、25 人 120 秒、50 人 1800 秒。预设标准：错误率≤1%、整体 P95≤2000ms、逐账号写入全部对账、DB quick_check=ok。本组实验验证 CPU 与数据库业务链路，采用所列负载和单 worker 配置；LLM 生成吞吐、最大容量与多机性能分别通过专项实验评价。

二、结果总表

测试组	最终实测结果	原始证据
后端源码回归	604/604 通过，0 失败，0 跳过	backend-junit.xml、backend-tests.log
功能 / 权限 / 跨角色协同	86/86 通过	functional-final.json
同账号多设备并发	100 请求；记录完整=True；掌握度一致=True	same-user-final.json
导学闭环（模型桩）	14/14 通过	smoke.json
运行包全新环境功能	86/86 通过	functional-runtime.json
运行包浏览器	23/23 通过；JS 错误 0	ui-final-runtime/results.json

测试组	最终实测结果	原始证据
运行包全新环境源码回归	604/604 通过，0 失败，0 跳过	runtime-backend-junit.xml、runtime-backend-tests.log
运行包导学闭环与边界（模型桩）	14/14 通过	runtime-smoke.json；runtime-algorithms.json 另列算法结果
真实视觉 API 与公网拍照流程	2/2 原创图片检查；拍照 SSE= 通过	vision-live.json
4090D 本地 GPU 推理性能	70/70 计时请求完成，4 组负载各重复 5 批，GPU 计算采样确认	gpu-4090d/benchmark.json；08 专项报告
云 GPU 部署功能 / 协同	86/86 通过；真实模型客户端接入另验收	gpu-4090d/functional.json
云 GPU 浏览器 / 角色导航	23/23 通过；JS 错误 0	gpu-4090d/ui/
本地 GPU 真实应用 SSE	2/2 通过，检索与流式回答完成	gpu-4090d/application-sse.json

本次完整处理后数据验收

2026-10-10 通过内容表白名单导出 4810 题、220 知识点、6086 判题样例、383 规则项、4980 题目知识点关联及 2646 检索块。运行包身份全新创建，初始个人行为表为空。验收在本机临时目录和回环入口执行，写入仅发生在一次性副本；本组验证 CPU / SQLite 业务链路。

检查	实测结果	证据
最新源码回归	621 项通过，0 失败；其中 17 项文档 / 数据导出工具用例	source-tests.log
完整内容功能 / 权限 / 协同	86/86 通过	functional.json
同账号并发回写	5 轮、100 请求，作答全部落库、掌握度与串行结果一致	same-user.json
四课程检索	4 组查询均返回 3 项结果	acceptance.json
初始内容与隐私结构	6 类内容表保留、7 个虚构身份，其他个人 / 实例表为空	数据清单
FTS 跨环境部署	正文、编号与引用指纹保持一致，SQLite 3.37.2 / 3.51.2 完整性检查均通过	索引清单

以下 30 分钟容量与 GPU 计时沿用各自已归档实测条件；新增内容包验收不替代历史设备、样本和延迟指标。

三、高并发容量与写入一致性

用户	实际时长 s	请求 / 失败	RPS	P95 ms	写入 / 对账	验收
10	60.13	4586/0	76.27	60.99	917 / 一致	通过
25	120.37	7731/0	64.23	547.55	1547 / 一致	通过
50	1800.77	113334/0	62.94	1281.92	22666 / 一致	通过

50 用户整体 P50=667.06ms、P95=1281.92ms、P99=1609.48ms。其他组完整分位数见原始 JSON。

50 用户接口	请求数	P50 ms	P95 ms	P99 ms
/auth/profile	12953	515.43	998.17	1273.87
/knowledge?course=os	12948	300.61	654.83	945.36
/learning/center?course=os	12950	716.02	1212.47	1530.47
/practice/recommend?course=os	12951	743.21	1238.39	1563.94
/problems/judge	22666	902.45	1467.07	1785.26
/problems?course=os	12956	533.61	1039.19	1365.01
/records/errors?course=os	12955	627.04	1247.3	1584.56
/records/mastery?course=os	12955	774.62	1374.91	1721.16

验收同时核对 HTTP 响应、业务结果、数据库实际新增记录与完整性，形成响应与持久化的双重验证。时延包含端到端请求排队，各接口分位数单独列示。实验在共享测试环境完成，统计结果对应所述工作负载与部署配置。

四、同账号并发与事务正确性

5 轮，每轮新虚构身份、初始掌握度 0.2618、10 客户端提交 20 次正确答案。总 100 次请求；每轮新增 20 条记录，并将实际掌握度与逐次串行算法值比较，避免掌握度饱和掩盖错误。结果：记录完整=True，掌握度一致=True。逐轮预期/实际值见 same-user-final.json。

源码回归覆盖多线程及独立进程累积、题库与旧 Tutor 会话交叉写入、故障注入整事务回滚、嵌套保存点、幂等索引迁移、连接并行上限、写者独立通道，以及同步请求连接复用、线程隔离和异常后恢复。故障注入属于主动健壮性测试，用于验证事务回滚与恢复行为。

五、算法与功能案例

CPU 代码样例、canonical 判定与四课程 FTS 冒烟见 algorithms.json；导学模型桩验证编排与回流，真实模型链路单独验收，回答准确率采用独立标注集评价。学生错答、申请复核、教师/助教反馈、正确复测、学情与复习作业协同的典型输入和输出见 06 案例展示及 functional-final.json。

真实视觉使用智增增 qwen3-vl-30b-a3b-instruct、temperature=0.0、max_tokens=2048；2 张原创印刷体图片检查转写内容，公网拍照流程验证图片→转写→错误诊断及 SSE 完成。输入图和实际事件见 vision-live.json 及 vision-*.png。本轮完成接入与限定样例验收，广泛手写、复杂公式、模糊照片和批量扫描件效果纳入后续专项评测。

六、适用范围、后续验证与复现

本轮容量证据覆盖 SQLite 单写者、单 worker 部署；后续专项验证包括跨机多 worker 容量、敌对代码隔离安全、长期真人教育效果与广泛手写/复杂扫描件准确率。当前重复提交按新练习处理，通用 Idempotency-Key 作为后续增强项，适用于网络响应丢失后的重试场景。演示视频时长约 4 分 39 秒，已纳入 V1.0 附件，见演示材料与文件校验。4090D 上的现有 FP8 基座与 LoRA 本地推理计时、批量吞吐和应用接入已完成专项验收，见 08 报告；GPU 训练成本、向量模型和跨设备对比按 07 协议扩展。正式结论以本轮已完成的验收范围为准。

按 README 运行 pytest、smoke 及 submission_algorithms；独立测试目录使用 submission_concurrency_suite.py 串行复现，并核对源码摘要、acceptance、write_reconciled 和 db_integrity。正式报告、证据和运行包通过版本标识与源码摘要建立对应关系，保持实测结果可追溯。