CourseLoop GPU 本地部署与推理性能专项报告

正式交付版本：v1.0。实测时间：2026-10-09T11:58:42.176714+00:00 至 2026-10-09T12:04:13.363344+00:00。应用源码快照：3a265650eb7cdd715adcb3a9c78855bffccdd8be。本报告组织已完成的 4090D 实验，保留测试环境业务容量验收与公网视觉验收的独立口径；实测快照标识用于证据追溯。

一、实验目标与硬件环境

在租借的独立 4090D 服务器部署 CourseLoop，验证现有基座与 LoRA 的本地推理、批量并发和应用调用，补充可复现的 GPU 性能证据。测试环境正式服务保持现有部署。

GPU：NVIDIA GeForce RTX 4090 D, 570.124.04, 24564 MiB, 425.00 W；CUDA 计算能力：[8, 9]。容器配额见 inventory.json 的 cgroup 字段，cpu.max=1800000 100000 对应 18 核配额，memory.max=64424509440 对应 60GiB；宿主 CPU 为 AMD EPYC 9754，宿主总资源与容器配额分别记录。

Python=3.10.15；vLLM=0.10.2；torch=2.8.0；torch CUDA=12.8；transformers=4.55.2；tokenizers=0.21.4；triton=3.4.0。完整依赖见 GPU 和应用环境锁定文件。

二、模型资产与服务配置

使用项目已有 Qwen3-14B-FP8 基座及 courseloop-408 rank16 / alpha32 LoRA，以 courseloop-default 别名提供兼容模型接口。FP8 基座采用 128×128 块量化，推理 dtype=bfloat16。LoRA 源自历史 4bit 训练路线，本轮在 FP8 基座上验证加载与推理；量化条件作为本实验配置单独记录。

基座文件清单 SHA256：47080db0eaab6917bcdf153974964487e368431c0d13ed160e474edd8d5c08b3；LoRA 文件清单 SHA256：ed8dab5514892a6a5c307c78515338e466e4f111e499b2f8bfe0d204d68a8927。各文件 SHA256、大小见 inventory.json，模型资产按授权独立保管，不随源码分发。

服务配置：单 GPU、单模型进程，max_model_len=4096、max_num_seqs=8、max_num_batched_tokens=4096、gpu_memory_utilization=0.90、max_loras=1、max_lora_rank=16；采用 eager 执行，关闭前缀缓存，temperature=0、seed=42、enable_thinking=false。完整启动命令见 service-command.json。

三、实验设计与指标定义

四组负载串行测试：短上下文单请求、长上下文单请求、4 并发批量、8 并发批量。每组先预热 1 批（请求数与并发一致），再重复 5 批；计时样例使用原创材料，固定输出 128 或

256tokens（ignore_eos=true），确保输出长度可比较。长上下文原始提示和实际输入 tokens 保存在 benchmark.json，benchmark_script_sha256 记录实际测试脚本摘要。

端到端时延由服务器回环 HTTP 客户端测量，包含 HTTP、排队和 GPU 执行；TTFT 为收到首个非空内容事件的时间。整体输出 tokens/s=实际输出 tokens 总数÷该组墙钟时间。平均值、中位数、P95 与每次原始计时均在 JSON 中记录，小样本 P95 采用线性插值。

每 200ms 调用 nvidia-smi 采样 GPU 利用率、驻留显存、功率与温度。驻留显存包含模型、服务缓冲与 KV 缓存，采样峰值与框架张量分配峰值属于不同指标。固定长度生成用于性能测试；自然结束的真实客户端调用另列为应用接入验收。

四、GPU 性能实测

负载	并发	批次 / 请求	输出 tokens	平均时延 ms	P95 时延 ms	首 token P95ms
single-short	1	5 / 5	128	10527.754	11408.28	132.626
single-long-context	1	5 / 5	256	21050.364	21498.537	257.276
batch-4	4	5 / 20	128	10820.146	11464.665	280.44
batch-8	8	5 / 40	128	10821.892	11497.432	422.217

负载	总输出 tokens	整体 tokens/s	显存峰值 MiB	利用率峰值%
single-short	640	12.158	21655.0	42.0
single-long-context	1280	12.161	21889.0	100.0
batch-4	2560	47.204	21889.0	54.0
batch-8	5120	94.422	21889.0	84.0

各组请求全部完成，输出长度核对通过，GPU 利用率采样确认计算设备实际参与。完整分位数、批次耗时、输入 / 输出 token 用量、输出及 GPU 采样见 benchmark.json。

五、应用部署与集成验收

独立原创演示数据库 36 题、4 讲义，配置本地 GPU 文本模型，应用同源提供前端与 API。功能、权限与教学协同检查 86/86 通过，原始证据见 functional.json。

四课程通过项目真实 ask_task 客户端与 grounded-qa 提示调用本地 LoRA，4 次响应传输与非空输出检查通过，原始输入、输出与耗时见 benchmark.json。本项确认真实应用接入，答案准确率采用独立人工标注评价。

公网视觉继续采用已验收的智增增专用 API；本 GPU 部署聚焦本地文本推理，视觉结果按 vision-live.json 单独呈现。当前检索为 FTS5，向量 embedding / rerank GPU 基准按采用向量路线时另行开展。

六、部署访问与复现

应用默认回环端口 18080，模型默认回环端口 18003。服务器地址由部署者私下提供，账号见 ACCESS.md；SSH 口令、供应商密钥与原始.env 保持独立管理。可通过 SSH 端口转发访问：http://127.0.0.1:18080/。

上述端口与服务配置属于 GPU 实验环境的复现方式；日常评审访问采用在线演示服务入口。GPU 实验服务是否在线由部署者管理，归档测试结果与复现参数独立提供。

```
ssh -L 18080:127.0.0.1:18080 -p <SSH 端口> <用户>@<GPU 服务器地址>
# 从仓库导出快照，部署目录名须含 courseloop-gpu-submission-且无.git
# 将授权基座放在 model/Qwen3-14B-FP8，适配器放在 model/courseloop-408
# 编译 frontend/dist；在部署目录分别创建应用与 GPU 虚拟环境
<应用环境>/bin/pip install -i https://pypi.tuna.tsinghua.edu.cn/simple -r requirements.txt
<GPU 环境>/bin/pip install -i https://pypi.tuna.tsinghua.edu.cn/simple -r requirements-gpu-
submission.txt
<应用环境>/bin/python scripts/submission_gpu_deploy.py configure --source-commit <40 位源码提交>
<应用环境>/bin/python scripts/submission_gpu_deploy.py model --vllm <GPU 环境>/bin/vllm
# 另一个终端启动应用；模型就绪后再运行基准，避免并行负载干扰
<应用环境>/bin/python scripts/submission_gpu_deploy.py app
<应用环境>/bin/python scripts/submission_gpu_test.py --out .private/gpu-benchmark.json --repeats 5
```

通过源码快照、模型文件摘要、完整服务命令和环境锁复现；CPU 业务容量见 05 报告，API 视觉链路见 06 报告，本地 GPU 性能见本报告。

七、适用范围与扩展方向

本轮验证 4090D 上的现有模型推理与应用部署，训练参数和历史训练结果见 04 报告；本轮按推理实验执行。与双 V100 的硬件对比需固定同一模型、量化、上下文和服务参数后分别实测；FP8 与历史 4bit 条件分别记录。长时间 GPU 容量、更多上下文长度、向量模型与 GPU 训练时长可按 07 协议扩展。

技术依据：vLLM FP8 量化、vLLM LoRA。

浏览器验收：23/23 通过，JS 错误 0；界面截图和结果见 ui/。

真实应用 SSE：2/2 通过，使用本地 GPU 模型完成材料检索、流式回答与最终事件，见 application-sse.json。